## ММО Гринин Олег ИУ5-22М Вариант 1

Задание 1. Для набора данных проведите кодирование одного (произвольного) категориального признака с использованием метода "count (frequency) encoding". Задание 2. Для набора данных проведите масштабирование данных для одного (произвольного) числового признака с использованием масштабирования по медиане. Задание 3. Для произвольной колонки данных построить гистограмму

```
Ввод [29]: import pandas as pd
import numpy as np
import seaborn as sns
from sklearn.preprocessing import RobustScaler
import matplotlib.pyplot as plt
```

Ввод [3]: df = pd.read\_csv('https://github.com/OlegusOfficial/ML/blob/main/weather.csv?raw=True')

Ввод [4]: df.head()

Out[4]:

	Unname	ed: 0	Date	Location	MinTemp	Max Temp	Rainfall	Evaporation	Sunshine	WindGustDir	WindGustSpeed	 Humidity9am	Humidity3pm	Pressure9ar
C		0	2008- 12-01	Albury	13.4	22.9	0.6	NaN	NaN	W	44.0	 71.0	22.0	1007.
1		1	2008- 12-02	Albury	7.4	25.1	0.0	NaN	NaN	WNW	44.0	 44.0	25.0	1010.
2		2	2008- 12-03	Albury	12.9	25.7	0.0	NaN	NaN	WSW	46.0	 38.0	30.0	1007.
3		3	2008- 12-04	Albury	9.2	28.0	0.0	NaN	NaN	NE	24.0	 45.0	16.0	1017.
4		4	2008- 12-05	Albury	17.5	32.3	1.0	NaN	NaN	W	41.0	 82.0	33.0	1010.

5 rows × 24 columns

Ввод [5]: df.Location.unique()

Ввод [6]: df.Location.isnull().any()

Out[6]: False

В Location пропусков данных - нет

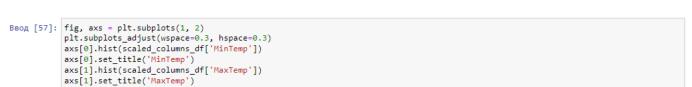
Count or frequency encoding

```
Ввод [7]: count_map_location = df['Location'].value_counts().to_dict()
```

```
Out[10]: {'Adelaide': 3090,
             'Albany': 3016,
'Albury': 3011,
              'AliceSprings': 3031,
              'BadgerysCreek': 2928,
              'Ballarat': 3028,
             'Bendigo': 3034,
'Brisbane': 3161,
              'Cairns': 2988,
              'Canberra': 3418,
              'Cobar': 2988,
              'CoffsHarbour': 2953,
              'Dartmoor': 2943,
              'Darwin': 3192,
              'GoldCoast': 2980,
              'Hobart': 3188,
              'Katherine': 1559,
              'Launceston': 3028,
              'Melbourne': 2435,
'MelbourneAirport': 3009,
              'Mildura': 3007,
             'Moree': 2854,
'MountGambier': 3030,
              'MountGinini': 2907,
              'Newcastle': 2955,
              'Nhil': 1569,
              'NorahHead': 2929,
              'NorfolkIsland': 2964,
             'Nuriootpa': 3002,
'PearceRAAF': 2762,
              'Penrith': 2964,
             'Perth': 3193,
'PerthAirport': 3009,
              'Portland': 2996, 
'Richmond': 2951,
              'Sale': 3000,
              'SalmonGums': 2955,
             'Sydney': 3337,
'SydneyAirport': 3005,
             'Townsville': 3033,
              'Tuggeranong': 2998,
              'Uluru': 1521,
              'WaggaWagga': 2976,
             'Walpole': 2819,
'Watsonia': 2999,
              'Williamtown': 2553,
              'Witchcliffe': 2952,
              'Wollongong': 2983,
'Woomera': 2990}
Ввод [8]: df['Location'] = df['Location'].map(count_map_location)
              Масштабирование по медиане
Ввод [27]: def arr_to_df(arr_scaled, arr):
                  res = pd.DataFrame(arr_scaled, columns=df[arr].columns)
                  return res
Ввод [30]: def draw_kde(col_list, df1, df2, label1, label2): fig, (ax1, ax2) = plt.subplots(
                       ncols=2, figsize=(12, 5))
                   # первый график
                   ax1.set_title(label1)
                  sns.kdeplot(data=df1[col_list], ax=ax1)
                  # второй график
                  ax2.set_title(label2)
                  sns.kdeplot(data=df2[col_list], ax=ax2)
                  plt.show()
Ввод [12]: df.MinTemp.isnull().any()
  Out[12]: True
Ввод [13]: mean_temp = df.MinTemp.mean()
             df.MinTemp.fillna(mean_temp, inplace=True)
Ввод [14]: df.MinTemp.isnull().sum()
  Out[14]: 0
BBOA [21]: scaler = RobustScaler() col = df[['MinTemp', 'MaxTemp']] scaled_columns = scaler.fit_transform(col)
```

Ввод [10]: count\_map\_location

```
Ввод [28]: scaled_columns_df = arr_to_df(scaled_columns, ['MinTemp', 'MaxTemp'])
             scaled_columns_df.describe()
  Out[28]:
                                      MaxTemp
                         MinTemp
                    142193.000000 141871.000000
             count
                         0.020261
                                       0.060853
              mean
                         0.694448
                                       0.691031
                std
                         -2.228261
                                       -2.660194
               min
               25%
                         -0.478261
                                       -0.456311
               50%
                         0.000000
                                       0.000000
               75%
                         0.521739
                                       0.543689
                                       2 475728
               max
                         2.380435
Ввод [32]: draw_kde(['MinTemp', 'MaxTemp'], df, scaled_columns_df, 'до масштабирования', 'после масштабирования')
                                 до масштабирования
                                                                                      после масштабирования
                0.030
                                                          MinTemp
                                                                                                               MinTemp
                                                          MaxTemp
                                                                                                                MaxTemp
                                                                       0.25
                0.025
                                                                       0.20
                0.020
                                                                     Density
0.15
                0.015
                                                                       0.10
                0.010
```



0.05

0.00

50

Out[57]: Text(0.5, 1.0, 'MaxTemp')

5000

0.005

0.000

